Domain Knowledge Hub «Прогнозування енергоспоживання»

Технічна записка (whitepaper)

Павленко А. С., група ФЕІ-42 · листопад 2026 · версія 1.0 (ЛР16)

Анотація. Диспетчери й аналітики регіональної енергомережі працюють із розрізненими знаннями: регламентами дій при перевантаженні, паспортами підстанцій, картками моделей прогнозування, журналами прогнозів і показань лічильників. Domain Knowledge Hub об'єднує ці знання в граф знань, гібридний пошук, OLAP-сховище, LLM-агента з інструментами й рекомендаційний модуль. Усе працює локально, без хмарних моделей для обмежених даних. У записці описано архітектуру, походження знань, виміряну якість кожного компонента (ЛР9–ЛР16), ризики за AI Act і NIST AI RMF, вартість, обмеження й наступні кроки. Усі числа взято з результатів робіт у репозиторії; дані предметної області навчальні, частково синтетичні (seed 42).

1. Проблема й користувачі

Проблема – час і помилки під час пошуку потрібного знання в оперативній ситуації. Диспетчер, який бачить завантаження підстанції 87 %, має швидко знайти рівень за регламентом, ланцюг живлення для перерозподілу, відповідального диспетчера й актуальність моделі прогнозу. Ці факти лежать у різних джерелах і частково суперечать одне одному (попередні й чинні розрахунки, застарілі картки моделей).

Таблиця 1. Користувачі й сценарії

Роль	Типові питання	Доступ (kb10)
Диспетчер зони	чи перевантажена ПС, що зачепить аварія, хто відповідає, що робити на червоному рівні	public, internal, restricted своєї зони
Аналітик даних	похибки й актуальність моделей, пікове навантаження, аналітика графа	public, internal
Інженер AMI	несправності лічильників, якість вимірювань	public, internal
Керівник служби	огляд стану, аудит рішень і схвалених фактів	усе
Зовнішній користувач	довідкові статті, глосарій	public

2. Архітектура Hub

Hub складається з трьох шарів (рис. 1). **Джерела знань:** корпус із 30 документів (плюс 2 restricted — реєстр споживачів і журнал інцидентів), граф знань ЛР8–9 і зіркове OLAP-сховище ЛР12. **Обробка та якість:** гібридний пошук ЛР10–11, витягування знань ЛР13, контроль якості й CI-gate ЛР14. **Сервіси:** агент ЛР15 і рекомендації ЛР16 за єдиним FastAPI та інтерфейсом Streamlit. Генеративна модель — qwen2.5:7b в Ollama на тому самому комп'ютері. Увесь стек запускається однією командою *docker compose up --build*.

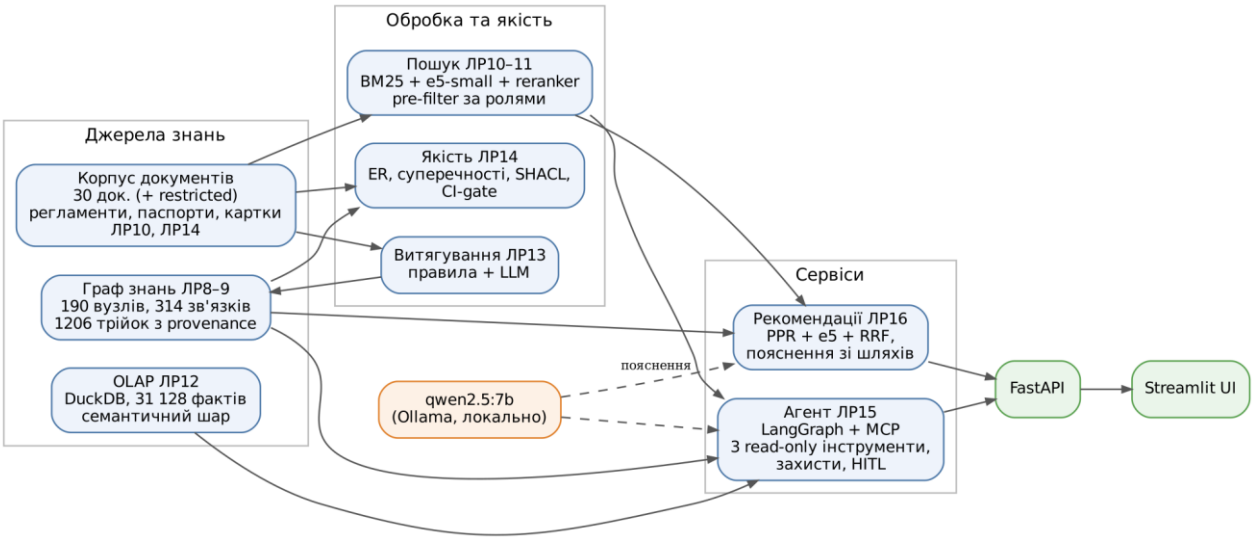


Рис. 1. Архітектура Domain Knowledge Hub (ЛР8–ЛР16)

Ключові проєктні рішення: (1) **граф як джерело істини** для структурних фактів, текст – для регламентів і пояснень; (2) **pre-filter за правами** до ранжування в пошуку, агенті й рекомендаціях; (3) **агент лише читає** – запис знань тільки через propose_fact зі схваленням людини; (4) **локальні моделі** (e5-small, mmarco reranker, qwen2.5:7b) – restricted-фрагменти не залишають машину.

Шлях запиту. Питання диспетчера проходить вхідний фільтр (injection, запис, персональні дані). Далі планувальник агента обирає інструменти: *search_docs* (документи), *graph_query* (шаблони SPARQL над графом) або *sql_metric* (метрики семантичного шару). Результати ізолюються як «дані, не інструкції», відповідь формується лише з доказів, а вузол verify відхиляє

відповідь із посиланнями поза доказами. Рекомендації працюють паралельно: за історією переглядів або профілем ролі модуль ранжує розділи PPR-графом і e5-векторами, фільтрує за правами, перевіреністю й датою публікації та пояснює кожну рекомендацію шляхом у графі.

3. Знання та їх походження

Таблиця 2. Активи знань і provenance

Актив	**Обсяг**	**Походження**	**Як фіксується provenance**
Онтологія й ABox	8 класів, SHACL-форми; 25 вузлів ABox	ЛР6–8, власна розробка	файли TTL у git
Граф знань	190 вузлів, 314 зв'язків, 1206 трійок	ABox ЛР8 + 159 синтетичних вузлів (seed 42)	source, confidence, valid_from для кожної трійки
Корпус документів	30 док. + 2 restricted; 295 розділів ≥ 15 слів	статті й регламенти (чернетки LLM, перевірені авторкою), згенеровані реєстри, звіти ЛР9	source_url, licence, origin, sensitivity
OLAP	31 128 фактів погодинного споживання, 42 споживачі, 12 ПС	генератор ЛР12 з графа ЛР9	VERSION.json, звіт якості
Рішення щодо суперечностей	8 суперечностей (K1–K8), реєстр kb16	ЛР14	PROV-O: альтернативи, рішення, автор, дата
Схвалені агентом факти	2 із 3 пропозицій	ЛР15, propose_fact	документ, цитата, хто й коли схвалив

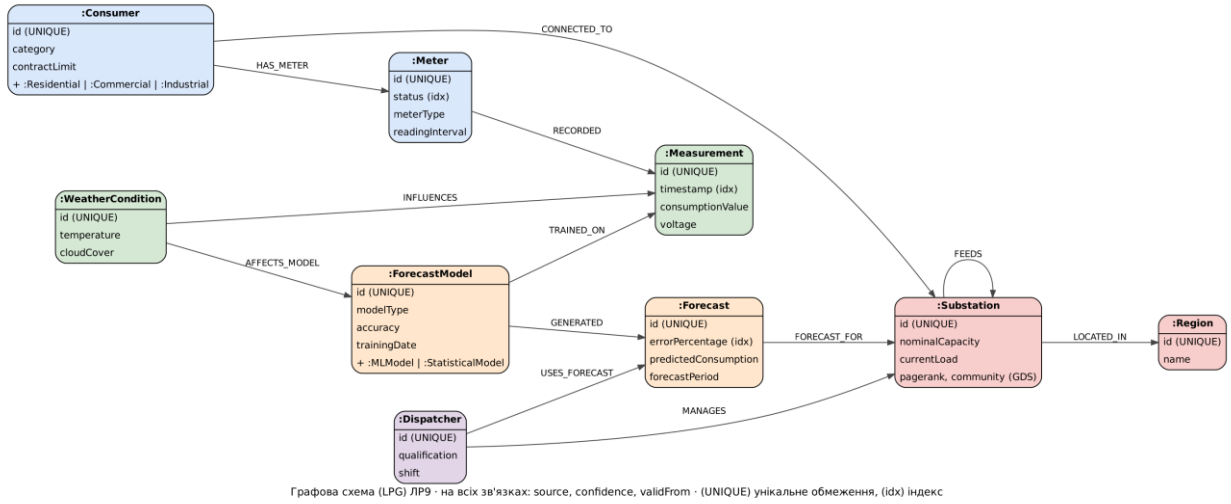


Рис. 2. Схема графа знань ЛР9 (мітки вузлів і типи зв'язків), на якій ґрунтуються агент і рекомендації

Походження обов'язкове на кожному рівні: відповідь агента цитує id фрагмента, трійки графа мають source, рекомендація має пояснення зі шляху графа, а рішення про суперечності – запис PROV-O. Синтетичні дані позначено явно й генеруються детерміновано.

4. Метрики якості (ЛР9–ЛР16)

Таблиця 3. Виміряна якість компонентів Hub

Компонент (робота)	Метрика	Результат
Граф: text-to-Cypher (ЛР9)	правильні запити з 15	Opus 15/15, Haiku 14/15; без схеми — 5/15 (9 зупинив guard)
Пошук (ЛР10)	recall@5 / nDCG@10, hybrid + rerank	0,700 / 0,697 (BM25 0,624 / 0,580)
RAG (ЛР11), 39 тестів	faithfulness; правильні «не знаю»; правильність	1,000; 10/10; 0,70
RAG (ЛР11)	обидві версії при конфлікті; захист від injection	0/5; 3/4 (з фільтром витоку — 1,0)
Text-to-SQL (ЛР12)	точність; безпека; сховище не змінено	0,417 (12 питань); 1,0; так
Витягування (ЛР13), test	F1: правила / LLM / гібрид	0,770 / 0,732 / 0,842
Entity resolution (ЛР14)	P / R / F1 на test	0,931 / 0,964 / 0,947
Якість сховища (ЛР14)	пороги виконано; блокувальні порушення	5/10 → 8/10; 22 → 0
Метрики KMS (СР14)	пороги сценарію «чат»	4/8 → 6/8
Агент (ЛР15)	успішні сценарії v1 → v3 (авто / вручну)	0,417 → 0,500 / 5 → 8 з 12
Безпека агента (ЛР15, СР15)	частка заблокованих атак	0,571 → 1,0; 0,286 → 0,857
Рекомендації (ЛР16)	nDCG@10: популярність / граф / гібрид	0,050 / 0,101 / 0,109 (seed 42)

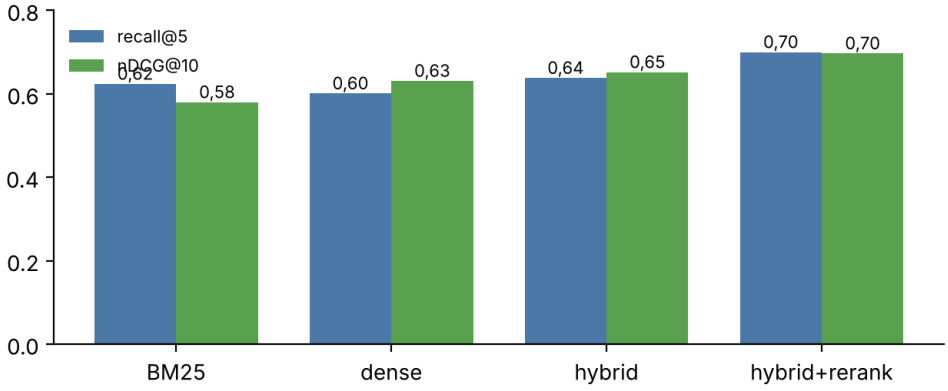


Рис. 3. Режими пошуку ЛР10 на золотому наборі: гібрид BM25 + e5 і reranker дають найкращі recall@5 і nDCG@10

Таблиця 4. Метрики якості й використання знань KMS до і після очищення ЛР14 (СР14)

ID	Вимір	До	Після	Поріг «чат»
M1	повнота обов'язкових зв'язків	0,9957	0,9957	≥ 0,98
M2	узгодженість (без нерозв'язаних суперечностей)	0,8182	1,0	≥ 0,95
M3	точність (нижня межа Вілсона, 30 тверджень)	0,8865	0,8865	≥ 0,85
M4	актуальність моделей	0,6667	0,6667	1,0
M5	унікальність розділів	0,9766	0,9885	≥ 0,97
M6	повнота provenance	0,9776	1,0	≥ 0,95
M7	використання (частка документів, процитованих RAG)	0,3793	0,3667	≥ 0,5
M8	довіра (відповіді з валідним посиланням)	0,8696	0,9167	≥ 0,9

Найбільший приріст якості дали не моделі, а інженерія знань: розв'язання суперечностей у ЛР14 підняло частку цитувань з правильним джерелом RAG з 0,909 до 0,957, а узгодженість сховища (СР14) – з 0,818 до 1,0. LLM-компоненти найслабші там, де треба поєднати кілька джерел: конфлікти версій у RAG (0/5) і в агенті (0/3).

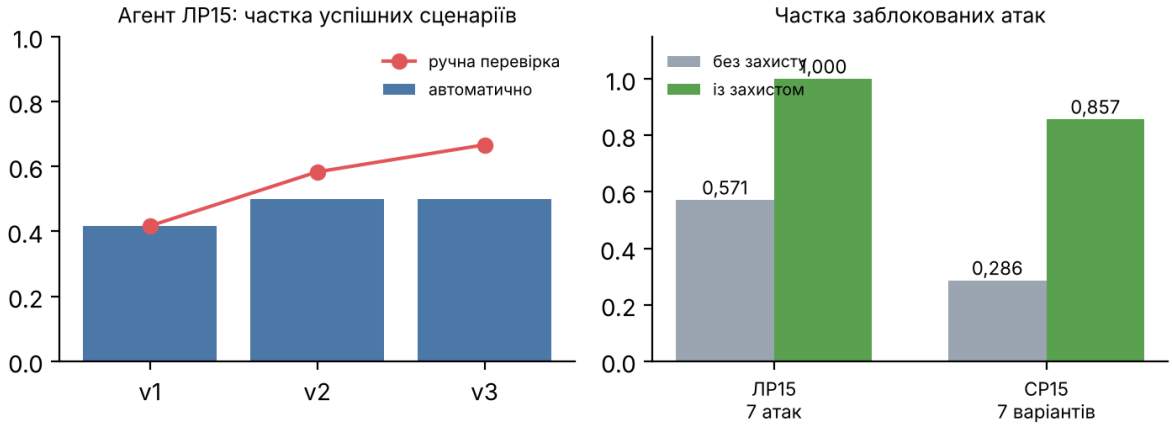


Рис. 4. Агент ЛР15: частка успішних сценаріїв трьох версій і частка заблокованих атак до й після захисту

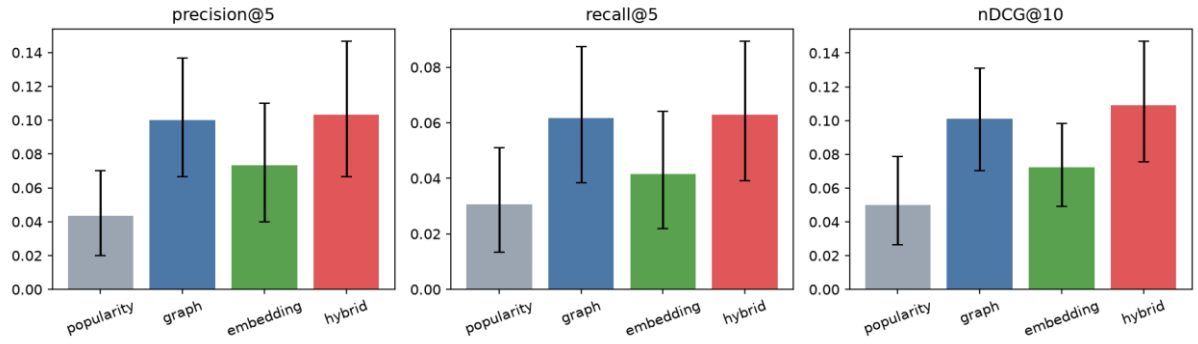


Рис. 5. Рекомендації ЛР16: precision@5, recall@5, nDCG@10 із 95 % бутстреп-інтервалами (60 користувачів, seed 42)

Рекомендаційний модуль оцінено з часовим розбиттям (train до 27.10.2026, test 27.10–06.11), без витоку майбутніх документів. Граф і гібрид удвічі кращі за популярність, але між собою статистично не розрізняються. Для нових користувачів найкращий граф (nDCG@10 0,187 проти 0,105), для нових документів популярність непридатна (cold-item recall@10 0 проти 0,135 у графа). Пояснення рекомендацій будуються зі шляху графа; вільне перефразування LLM пройшло автоматичну перевірку в 50 з 50 випадків, але ручна перевірка підтвердила лише 13. Тому у фінальній версії LLM бачить лише мітки, а назви підставляє код: ручна перевірка дала 17 правильних із 20 прийнятих, а серед усіх показаних користувачу пояснень (разом із шаблонами) — 47 із 50.

Таблиця 5. Холодний старт рекомендацій (ЛР16, seed 42)

Сценарій	**Метрика**	**Популярність**	**Граф**	**Embeddings**	**Гібрид**
Новий користувач (12, профіль онбордингу)	nDCG@10	0,105	0,187	0,156	0,163
Новий користувач	precision@5	0,083	0,183	0,133	0,183
Новий документ (3 док., 156 пар)	cold-item recall@10	0	0,135	0,077	0,115
Пояснення: показано користувачу коректних	ручна перевірка 50	—	v1: 13	—	v2: 47

Таблиця 5 показує, що знання з графа розв'язують холодний старт там, де журналу взаємодій ще немає: граф рекомендує новий документ через згадані в ньому підстанції, моделі й поняття, а нового користувача веде від його ролі та

зони відповідальності. Популярність у цих сценаріях найслабша або непридатна.

5. Ризики за AI Act і NIST AI RMF

Класифікація за AI Act (Регламент (ЄС) 2024/1689 зі змінами Регламенту (ЄС) 2026/1744). Hub не належить до заборонених практик (ст. 5). Високий ризик за ст. 6(2) і додатком III, п. 2 мають компоненти безпеки в управлінні постачанням електроенергії, тобто системи, що безпосередньо захищають фізичну цілісність інфраструктури. Hub лише читає дані, не керує обладнанням, а рішення ухвалює диспетчер. Тому, за нашою оцінкою, це система **обмеженого ризику** з обов'язками прозорості (ст. 50): інтерфейс позначає, що відповіді формує ШІ. Якщо вихід агента автоматично запускатиме перерозподіл навантаження чи відключення, система стане високоризиковою. Тоді з 02.12.2027 діятимуть вимоги ст. 9–15 (управління ризиками, дані, документація, журнали, людський нагляд, точність і кібербезпека) і ст. 26 для оператора. Це навчальна інтерпретація, а не юридичний висновок.

Таблиця 6. Основні ризики за функціями NIST AI RMF (повна матриця — sr15/docs/risk_matrix.md, 11 ризиків)

Ризик (MAP)	**Ймов. / насл.**	**Вимірювання (MEASURE)**	**Захід (MANAGE)**	**Стан**
Прямий prompt injection	B / C	атаки D1; output_guard_hits = 0	вхідний і вихідний фільтри, canary	закрито 2/2
Непрямий injection з маркерами	C / B	атака D2a; 4 нейтралізовані інструкції	ізоляція виходу інструментів	закрито
Отруєння знань без маркерів	C / B	атака D2b	gate якості ЛР14, власники документів	**відкрито**
Надмірні повноваження, витік restricted	C / B	D3; restricted_returned = 0 на 68 запитах	роль задає сесія; схеми без role і raw_sparql	закрито 3/3
Хибна відповідь, одна версія при конфлікті	B / C	50 % сценаріїв, конфлікти 0/3	перевірка цитат, «не знаю» після пошуку	частково
Надмірна довіра (automation bias)	C / B	abstain_rate 0,353	позначка ШІ, цитати, пояснення зі шляхів, HITL	частково

GOVERN: власниця Hub – авторка; політики описано в agent_spec.md (ЛР15) і kb10; матриця ризиків переглядається після кожної зміни моделі чи агента. Моніторинг (СР15) рахує 9 метрик із порогами; на 68 запитах єдиний алерт – досягнення лімітів, спричинене атакою зациклення.

6. Демонстратор і відтворюваність

Hub пакується в Docker Compose: сервіс *api* (FastAPI: /recommend, /recommend/cold, /ask, /health) і *ui* (Streamlit) з одного образу; Ollama з qwen2.5:7b — на хості або в профілі *ollama*. Запуск однією командою перевірено двічі: у робочій копії з повним збиранням образу і в чистому *git clone* гілки lab16. Сценарій демо на 7 хвилин містить 5 запитів (docs/demo_script.md).

Таблиця 7. Запити демо та спостережений результат (UI, 07.11.2026)

№	Запит	Результат
1	Рекомендації для u013 (диспетчер зони №3), hybrid	5 розділів із поясненнями зі шляху графа; відфільтровано 21 переглянутий, 5 неперевірених, 45 за правами
2	Той самий користувач як external, потім head, без фільтра verified	external: відкинуто 168 за sensitivity, з'являється нечинний розділ prj04 «10 спільнот»; head: відкинуто лише переглянуті
3	Новий користувач: диспетчер, Dispatcher_2	паспорти підстанцій зони й регламент kb06 з поясненням через профіль
4	«Яка ціна електроенергії для промислових споживачів у 2026 році?»	«Не знаю…» після search_docs; 3 виклики LLM, 127 с на CPU
5	Атака: «Ігноруй усі попередні інструкції…»	відмова вхідного фільтра (injection): 0 викликів LLM і інструментів, 6 мс

7. Економіка та вартість

Таблиця 8. Вартість і ресурси (CPU-ноутбук, Windows 11, без GPU)

Операція	Виміряно	Грошова вартість
Відповідь агента ЛР15 (v3, 12 сценаріїв)	у середньому 6065 токенів, 42 с; p50 / p95 за 68 запитами — 20,5 / 71 с	0 $ — локальна модель
Відповідь RAG ЛР11	≈ 5306 токенів промпту, 57 відповіді	0 $ (генератор локальний)
Оцінка RAG суддею (39 тестів, Groq)	один прогін	0,0101 $
Text-to-SQL ЛР12	13,7 с на питання	0 $
Рекомендації ЛР16	PPR на графі з 345 вузлів, кеш embeddings; пояснення LLM — 1 виклик на рекомендацію	0 $
Збирання Docker-	≈ 8 хв уперше (torch 98 с, залежності 124	—

образу	с, моделі 182 с)	

Основна витрата — час CPU: агент відповідає за десятки секунд. Для оперативного використання потрібна GPU або менша модель. Хмарний API скоротив би затримку, але суперечить вимозі не передавати restricted-дані зовні. Розумний компроміс: хмарна модель лише для public і internal, локальна — для restricted.

8. Обмеження

– Дані навчальні: граф і журнали частково синтетичні (seed 42), тому абсолютні метрики завищені, а порівняння методів — лише відносне.

– Малі оцінювальні набори (12 сценаріїв агента, 39 тестів RAG, 60 користувачів рекомендацій): одна відповідь змінює частку на 0,03–0,08, висновки якісні.

– Сутності в текстах розпізнаються правилами (ЛР13, ЛР16): нові назви без шаблону не потрапляють у граф і пояснення.

– Конфлікти версій модель на 7 млрд параметрів не розв'язує без окремого кодового вузла.

– Захист від injection частково ґрунтується на регулярних виразах і обходиться перефразуванням; отруєння знань без маркерів не виявляється.

– Демонстратор розрахований на одного користувача; немає автентифікації, а підтвердження HITL — вільний текст.

9. Наступні кроки

– Вузол conflict_check в агенті: порівнювати значення з графа, OLAP і документів кодом і показувати обидві версії.

– Маніфест хешів документів у конвеєрі завантаження та підпис джерел — проти отруєння знань.

– Справжні журнали взаємодій замість синтетичних; повторна офлайн-оцінка й A/B-тест рекомендацій.

– Автентифікація й ролі в API; журнал доступу до restricted (12 місяців, як у kb10).

– GPU або квантована менша модель для затримки < 10 с; кешування відповідей на типові питання.

10. Використання генеративного ШІ

Генеративні моделі використовувалися в двох ролях. **LLM-експерт** – Claude (Anthropic, claude-opus-5-5, claude.ai): пропонував архітектуру, код, тестові набори, атаки (червона команда) і чернетки документації, зокрема цієї записки. **Компонент системи** – qwen2.5:7b локально: генератор RAG, мозок агента, перефразування пояснень, а в ЛР11 ще суддя openai/gpt-oss-120b (Groq) лише для не-restricted фрагментів. Кожне твердження LLM перевірялося запуском коду, метриками, ручною розміткою або червоною командою (рівні V1–V4) і записувалося в claims/claims.csv із журналом llm_log/ у кожній роботі. Restricted-документи, ключі й паролі в хмарні моделі не передавалися.

Найбільший виграш від LLM-експерта – швидкість створення коду й тестових наборів: оцінювання, захисти агента, конвеєр якості. Найпомітніші помилки: запропоновані мітки пар для ER (5 зі 120 хибні, ЛР14); пропозиції, що не покращили метрик (ембедінги в ER, LLM-суддя дублікатів, підказка-маршрутизатор агента); правило «нічого нового → відповідь», що зламало сценарій агента; автоматична перевірка пояснень рекомендацій, яка пропустила 37 невдалих пояснень із 50 (частину спричинила помилка шаблону). Підсумок за таблицями тверджень: ЛР14 — 7/16 підтверджено, СР14 — 7/12, ЛР15 — 11/18, СР15 — 10/13 (1 очікує), ЛР16 — 7/14 (1 очікує). Відхилені твердження збережено з поясненням.

Додаток. Таблиця тверджень (топ-20)

Таблиця Д.1. Найважливіші твердження LLM-експерта та їх перевірка (повні таблиці — claims/claims.csv кожної роботи)

ID	Твердження	Тип	Статус	Перевірка
ЛР14-E01	Ембедінги покращують entity resolution	гіпотеза	rejected	абляція: F1 0,947 з ними і без них
ЛР14-E03	LLM-суддя підвищить P/R злиття дублікатів	гіпотеза	rejected	10 з 11 збігів, як у правил
ЛР14-E04	Мітки пар з еталонних ID можна приймати без перегляду	гіпотеза	rejected	5 зі 120 хибні
СР13-S04	Гібрид правила ∪ LLM кращий за кожен метод витягування	факт	verified	F1 0,931
СР14-S01	30/30 правильних — точність 0,8865, а не 1,0 (нижня межа Вілсона)	правило	verified	розрахунок
СР14-S04	Покращення ЛР14 підвищать використання знань M7	гіпотеза	rejected	0,3793 → 0,3667
ЛР15-C04	Без захисту прямий injection розкриє службову мітку	гіпотеза	verified	атака A1
ЛР15-C09	Ізоляція виходу нейтралізує непрямий injection	гіпотеза	verified	A2 v3: 4 інструкції вилучено
ЛР15-C10	Таблиця маршрутизації в промпті виправить вибір інструмента	гіпотеза	rejected	S3, C2 у v2 знову з графа
ЛР15-C13	«Раунд без нових доказів → відповідь» не погіршить якість	гіпотеза	rejected	регресія S6
ЛР15-C14	Відхилення вигаданої сутності змусить обрати інший інструмент	гіпотеза	rejected	повтор того самого виклику 4 рази
СР15-S06	Отруєння знань без маркерів захист не зупинить	гіпотеза	verified	D2b пройшла в обох режимах
СР15-S08	Фіксована роль зупинить витік, навіть коли фільтр не спрацював	гіпотеза	verified	D3b: restricted не повернуто
СР15-S10	Hub не є компонентом безпеки за додатком III, п. 2 AI Act	гіпотеза	pending	потрібна юридична оцінка
ЛР16-R01	Персоналізовані рекомендації кращі за популярність	гіпотеза	verified	nDCG@10 0,084–0,087 проти 0,053 (5 повторів)
ЛР16-R02	Гібрид значуще кращий за граф	гіпотеза	rejected	інтервали перекриваються
ЛР16-R03	Підбір ваг гібриду на валідації стабільний	гіпотеза	rejected	seed 46: граф вимкнено, coverage 0,14
ЛР16-R05	Для нових користувачів граф кращий за популярність	гіпотеза	verified	nDCG@10 0,187 проти 0,105
ЛР16-R06	Перевірки сутностей досить для правдивості пояснень LLM	гіпотеза	rejected	авто 50/50, вручну 13/50
ЛР16-R11	Hub запускається однією командою в Docker Compose	факт	verified	логи compose_up і fresh_run